

スパイキングニューラルネットワークを用いた ドローン飛行制御に関する研究調査

A Survey on Spiking Neural Network for Drone Flight Control

指導教員：福田盛介 教授

修士課程 1 年 37-256564 平田涼馬

Abstract

AI-based flight control for drones has gained significant attention for applications in unknown and dynamic environments. Particularly, in environments where communication delays are significant, such as Mars, there is a need for AI models that can operate onboard, and the application of Spiking Neural Networks (SNNs) is anticipated. This survey analyzes recent research related to SNN-based drone flight control, focusing on (1) methods using reinforcement learning, (2) methods using imitation learning, and (3) methods combined with event-based vision sensors. Finally, we summarize and compare the key results of each approach and discuss their future prospects to the flight control of Mars exploration drones.

1 序論

ドローンは地形や障害物の影響を受けにくい高い移動能力や導入・運用コストの低さなどの特徴から農業や建設、物流、惑星探査など幅広い用途への応用が進んでいる。これらの応用において、高い自律性を持つドローンの開発が求められている。ドローンの飛行制御には、従来の制御理論に基づく PID 制御やモデル予測制御などが用いられることが一般的であったが、これらの手法には未知の環境や動的な環境への適応性、複雑なタスクの遂行能力に限界がある。これらの課題に対処するため、近年ではニューラルネットワークを用いた制御手法に注目が集まっている [1]。ニューラルネットワークを用いたドローン制御ネットワークの推論は、通信を用いて高性能なコンピューターにデータを送信して推論を行う方法と、ドローンに搭載したエッジデバイスで行う方法に大別される。通信を用いる場合、高い計算能力を利用して高度な行動計画を立てたり、高い精度での物体認識などを活用した制御が可能である一方で、通信遅延の影響からリアルタイム性に欠けるという課題がある。一方、エッジデバイスを用いる場合、リアルタイムでの制御が可能であるが、電力の使用が飛行時間の短縮につながってしまう点や、計算能力の不足からモデルの軽量化を行った結果、推論精度が低下するという課題がある [2]。これらの課題に対処するため、省電力かつ高効率な計算が可能なスパイキングニューラルネットワーク (SNN) を用いたドローンの飛行制御手法が注目されている。

1.1 スパイキングニューラルネットワーク

スパイキングニューラルネットワーク (SNN) とは、生物の脳が 0,1 のスパイクを用いて情報伝達することを模倣した AI モデルである。このスパイクを処理するニューロンのモデルとして使用されているのが LIF モデルである。LIF モデルは、以下の式で表される。

$$\tau_m \frac{dV(t)}{dt} = (-V(t) + E_{rest}) + I(t) \quad (1)$$

ここで、 $V(t)$ は膜電位、 E_{rest} は静止膜電位、 $I(t)$ は入力電流、 τ_m は膜時定数を表す。スパイクが入力されると、膜電位が上昇し、入力が無い場合は静止膜電位に向かって減衰する。連続でスパイクが入力されることで、膜電位が閾値を超えるとニューロンが発火し、出力スパイクを生成する。SNN の特徴として、入出力情報が 0,1 のスパイクで表現されることや、スパイクの入出力がある場合のみニューロンが活動するため、専用のニューロモルフィックチップ上に実装した場合、計算量が少なく、省電力、リアルタイム処理が可能であることが挙げられる。一方で、SNN は入出力で扱うスパイクが微分不可能であるため、ANN で一般的に用いられる誤差逆伝搬法を直接適用できないため、学習が困難であるという課題がある。現状、SNN の学習手法としては、ANN で学習したパラメータを SNN に変換する手法や、代理勾配を用いて誤差逆伝搬法を適用する手法などが用いられているが、ANN と比較して学習効率が低いという課題がある。また、ニューロモルフィックチップの性能

も発展途上であり、ANN と比較して計算能力が劣る場合が多い。

1.2 火星探査への展望

火星探査において、ドローンは地形の把握や科学観測、通信中継など多様な役割を担うことが期待されている。NASA の火星ドローン「Ingenuity」は、火星大気中での飛行実証を成功させ、その後も複数の飛行ミッションを遂行している [3]。将来的な火星探査ミッションでは、ドローンがより高度な自律飛行能力を持つことが求められており、未知の地形や動的な環境に適応できる制御手法の開発が必要である。この制御手法として、SNN を用いたドローン制御は、省電力かつリアルタイム処理が可能であるため、火星探査ドローンへの応用が期待されている [4]。



図 1: Ingenuity Mars Helicopter ([3])

1.3 本調査の目的

本調査では、ドローンの飛行制御において、SNN のネットワークを姿勢安定化や移動などの低レベル制御に用いた 2 つの研究と、経路計画を含めたナビゲーションに SNN を用いた 1 つの研究について紹介する。1 本目の研究では、IMU センサーを用いて姿勢推定と制御を行うことを提案した Neuromorphic attitude estimation and control [5] を紹介する。2 本目の研究では、入力にイベントカメラを使用し、自己教師あり学習と進化アルゴリズムを組み合わせた複合学習により視覚ベースの自己運動制御を行うことを提案した Fully neuromorphic vision and control for autonomous drone flight [6] を紹介する。3 本目の研究では、強化学習アルゴリズムである PPO により SNN を学習させてドローンの高機動ナビゲーションを行うことを提案した Bio-Inspired Drone Control A Reinforcement Learning-Trained Spiking Neural Networks for Agile Navigation in Dynamic Environment [7] を紹介する。最後に、各手法の分析から将来の火星探査ミッションにおけるドローン飛行制御への応用可能性について議論を行う。

2 SNN によるドローンの低レベル制御

2.1 IMU と模倣学習による姿勢推定・制御

2.1.1 概要

この研究では、ドローンの自律制御を単一のニューロモルフィックチップのみで実現することを目的として、IMU の入力からモーターコマンドを出力する SNN ベースの制御システムを提案している。本手法では、学習時にネットワークを姿勢推定と制御の 2 つのサブネットワークに分割し、それぞれを教師あり学習、模倣学習で訓練すること、SNN を用いることにより生じるセンサーバイアスやフィードフォワード遅延に対象するための工夫を行っている。また、提案手法は Crazyflie 上に実装され、評価が行われた。

2.1.2 ネットワーク構成

本手法では、ネットワークへの入力として IMU を用いている。IMU は加速度センサーとジャイロスコープから構成され、ドローンの 3 自由度の加速度と角速度を提供する。ネットワーク全体の構成は図 2 に示す通りである。

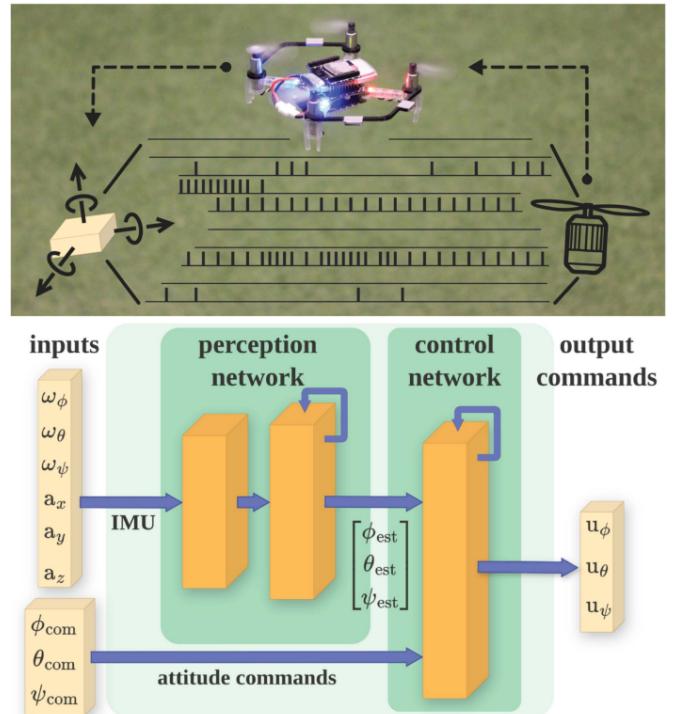


図 2: SNN network architecture ([5])

2 つに分割されたサブネットワークの前段では、IMU の 6 つの入力から、ドローンの姿勢の推定値が算出された。次に、ネットワークの後段では姿勢の推定値と目標の姿勢が入力され、モーターのトルクコマンドが output された。このネットワークに用いられたニューロンモデルはシナプス電流の時間変化を考慮した CUBA-LIF モデルで、以下の式で

表される。

$$\begin{aligned} v_i(t+1) &= \tau_i^{mem} v_i(t) + i_i(t), \\ i_i(t+1) &= \tau_i^{syn} i_i(t) + \sum_j W_{ij} s_j(t) \end{aligned} \quad (2)$$

ここで扱われる入出力はスパイクであるが、ネットワークの入出力は連続値であるため、線形層を用いた変換が行われている。これにより、スパイクのエンコードとデコードを学習に組み込むことで、最適化された変換を可能にしている。また、学習時には分割

$$\begin{bmatrix} \phi_{\text{est}} \\ \theta_{\text{est}} \\ \psi_{\text{est}} \end{bmatrix} = W_i W_o s(t) \quad (3)$$

2.1.3 SNN の学習方法

SNN の学習には模倣学習が用いられた。学習データは、姿勢推定に相補フィルタ、制御にカスケード PID 制御を使用し手動で 20 分間飛行させ、500Hz で収集された。学習には、教師あり BPTT が用いられ、損失関数は以下の式で表される平均二乗誤差 (MSE) とピアソンの相関損失を組み合わせたものとして定義された。

$$J(p) = \text{MSE}(x, \hat{x}) + \frac{1}{2}(1 - \rho(x, \hat{x})) \quad (4)$$

また、非連続なスパイク関数の微分を近似するために、代理勾配が用いられた。本手法では、スケール付きアークタンジェントの導関数であり、以下の式で表される。

$$\frac{d}{dx} \left(\frac{1}{s} \arctan(sx) \right) = \frac{1}{1 + (sx)^2} \quad (5)$$

SNN は、電流と電圧のリーコンストラクションを考慮するため、時間情報を集約するメモリを暗黙的に持つため、出力に遅延が生じる。この遅延を補償するために、学習データのラベルを 6 ステップ先の値にシフトさせて学習が行われた。さらに、模倣学習を用いた事による現実とのギャップを低減するために、学習データの拡張が行われた。具体的には、(i) 初期の学習データで訓練された SNN を用いて飛行させ、その時に学習データ用のコントローラーで得られるはずだったデータ、(ii) 通常の PID のコントローラーにランダムな外乱を加えたデータ場合のデータが収集され、学習データに追加された。これらのデータ拡張により、より広範な状態空間での学習が可能となり、現実世界での適応性を向上させている。また、制御ネットワークの学習において、正解ラベルとした PID 制御器の積分器は学習を行うことが困難であった。これに対して、ネットワークのニューロンの一部の膜時定数を 1 に設定することで、入力信号を積分することを可能にする工夫が行われた。

2.1.4 制御精度の評価

位置移動の能力を評価するために、提案手法を用いて 1m 前進し原点に戻るタスクを実施し、通常の PID 制御との比較が行われた。タスクは 10 回施行され、提案手法は全ての施行で PID 制御と同等の性能を示し、安定した目標追従が可能なことが示された。次に、各学習方法による SNN 制御と PID 制御による姿勢応答の比較を行ったため、ロールを 0° , $+10^\circ$, -10° , 0° と変えて行ったときの応答の比較が行われた（図 3）。提案手法において、ロール角の目標値と制御値の RMSE は 3.03° であり、姿勢推定及び制御が正確に行われてことが示された。また、PID の RMSE は 2.67° であり、提案手法より高い精度であったが、これは外部から姿勢情報を直接与えられており、制御のみが誤差の要因であるためだと考えられる。提案手法では、姿勢推定と制御の両方が誤差の要因となるため、このことからも提案手法は十分な精度を達成していることが示された。

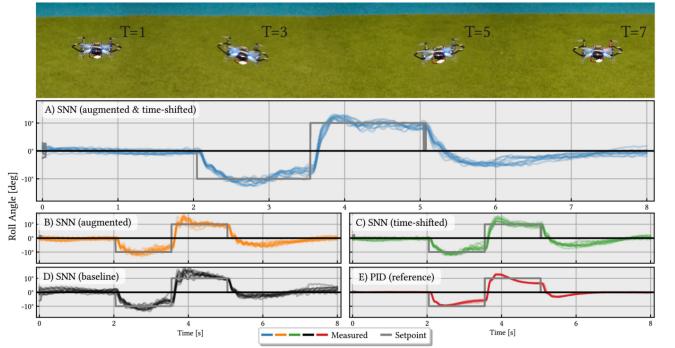


図 3: Attitude step responses of A) the fully-trained SNN system, B) the SNN trained with augmentation, C) the SNN trained with time-shifted data and D) the regular PID flight stack. The images on top show the Crazyflie during the different maneuvers. ([5])

2.1.5 消費電力の分析

最後に、本手法における消費電力の分析が行われた。提案手法は使用した小型クアッドローターに対して、現在利用可能なニューロモルフィックチップが大きすぎたため、従来のマルチプロセッサにて実装が行われた。一方で、SNN を用いることによる省電力性は単一のニューロモルフィックチップで動作させた場合に得られる。そのため、潜在的な消費電力の削減効果を評価するために、ネットワークが行う演算数に基づいて、消費電力の推定が行われた。その結果、PID ベースの制御は 3000 回の加算、提案手法は 7500 回の加算が必要と等価と見積もられ、SNN 制御器は PID 制御と同じ桁のエネルギー効率を達成することが推定された。このエネルギー効率は、将来的にシステムが画像処理タスク

クと統合された場合に、スパイクの疎性により乗算を削減できるため、向上すると考えられている。また、イベントベース制御への拡張により、ホバリングなどの制御を行わない場合に、更に消費電力を削減できる可能性があると示唆された。

2.1.6

本手法で示された、SNN の学習時のデータ拡張や、積分動作のニューロンによる実装などは、手法を拡張させる際にも有効であると考えられる。一方で、ラベルをシフトさせる手法は、ドローンの動きが複雑可する場合や、移動速度が早くなる場合には適切に補償できなくなる可能性がある。そのため、より一般的に適用可能な遅延補償手法の検討が必要であると考えられる。また、示された電力効率は PID 制御と同等の桁であることが主張されたが、2 倍以上の計算量であり、特にバッテリー量が限られる火星ドローンにおいては無視できない差である。そのため、画像を用いた制御と統合した場合の消費電力と精度のトレードオフの分析が必要であると考えられる。

2.2 イベントカメラと複合学習による視覚ベースの自己運動制御

2.2.1 概要

この研究は、イベントカメラを用いて取得したイベントベースの視覚情報を入力とし、低レベルの制御アクションを出力する SNN を提案している。ネットワークは視覚処理部と制御部にモジュール分割されており、視覚処理部は自己教師あり学習、制御部はシミュレーター上で進化アルゴリズムを用いた学習が行われた。また、提案手法は Intel Loihi プロセッサを用いて実装され、評価が行われた。

2.2.2 イベントカメラの特性

本手法では、視覚処理を行うためのセンサーとしてイベントカメラを用いている。イベントカメラは、従来のフレームベースのカメラとは異なり、ピクセル毎に独立して輝度変化を検出し、変化があった場合のみイベントとして出力するセンサーである。この特性から、 μs オーダーの高い時間分解能、広いダイナミックレンジ、低消費電力などの利点を持ち、スパイクで情報を処理する SNN と相性が良い。

2.2.3 イベントベースのオプティカルフロー

オプティカルフローとは、連続する画像間での物体の動きを表すベクトル場である。

2.2.4 提案システムの概要

この研究では、4 に示すシステムが提案された。ドローンには、イベントカメラ、ニューロモルフィックプロセッサ、シングルボードコンピュータおよびライトコントローラーが搭載され、イベントカメラからの情報を制御コマンドに変換する SNN がニューロモルフィックプロセッサ上で実行される。SNN の視覚処理部は、Loihi チップ上でイベントベースのオプティカルフローを実装する上で課題となる計算リソースの制約を克服するために、イベントカメラは静的でテクスチャが豊富な平坦な表面を見下ろしていることが前提となっている。この条件で、イベントカメラの画像平面の内、コーナーの関心領域からの情報のみが用いられ、更に ROIあたりのイベント数を 90 に制限することで、200Hz の動作周波数が実現されている。

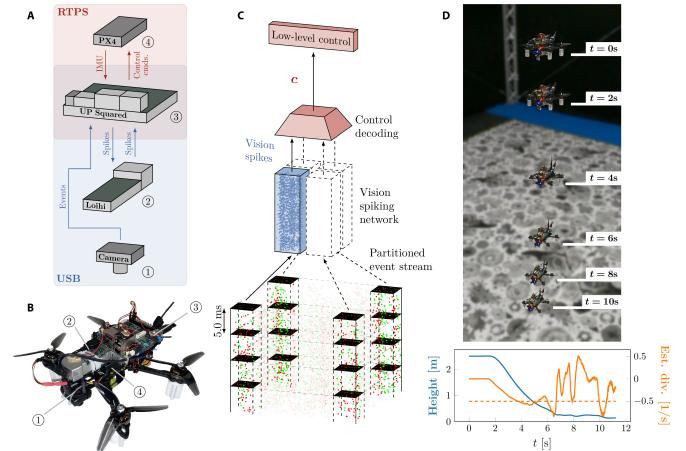


図 4: Overview of the proposed system ([6])

2.2.5 SNN の学習手法

2.2.6 シミュレーションと実飛行での制御精度の比較

2.2.7 手法の考察

3 SNN による高機動ナビゲーション

3.1 概要

本研究では、深層強化学習アルゴリズムである近位ポリシー最適化 (PPO) を使用して SNN 飛行ポリシーの学習が行われた。この飛行ポリシーでは、システムの状態をドローンの低レベルの制御コマンドに変換することを提案している。本手法はシミュレーション上でリングを回避しながら進むタスクにて、SNN の低計算量で時間情報を処理することが可能な特性を活かし、ANN と比べて高い成功率で、完了時間も短縮可能なことが示された。

3.2 PPO アルゴリズムによる SNN エージェントの学習

提案されたフレームワークでは、物理シミュレーション環境、PPO アルゴリズムで学習された SNN ベースのエージェント、低レベルコントローラーが組み合わされている。高速で移動するゲートを通過するタスクにおいて、SNN エージェントはシミュレーションステップ毎に、システムの状態 $s \in \mathbb{R}^{19} := (d_{tgt}, q, v, \omega, d_{gate}, v_{gate})$ を受け取る。ここで、 d_{tgt} は目標位置までの距離、 q, v, ω はドローンの姿勢、速度、角速度、 d_{gate} はドローンと次のゲートの中心との距離、 v_{gate} はゲートの中心の速度を表す。

4 まとめ

参考文献

- [1] Patrick McEnroe, Shen Wang, and Madhusanka Liyanage. A survey on the convergence of edge computing and ai for uavs: Opportunities and challenges. *IEEE Internet of Things Journal*, Vol. 9, No. 17, pp. 15435–15459, 2022.
- [2] Sifat Rezwan and Wooyeon Choi. Artificial intelligence approaches for uav navigation: Recent advances and future challenges. *IEEE access*, Vol. 10, pp. 26320–26339, 2022.
- [3] NASA. Ingenuity mars helicopter image gallery, 1 2024.
- [4] David AR Harbour, Kelly Cohen, Steven D Harbour, Bradley Ratliff, Alex Henderson, Hallie Pennel, Stephen Schlager, Tarek M Taha, Chris Yakopcic, Vijayan K Asari, et al. Martian flight: Enabling motion estimation of nasa’s next-generation mars flying drone by implementing a neuromorphic event-camera and explainable fuzzy spiking neural network model. In *2024 AIAA DATC/IEEE 43rd Digital Avionics Systems Conference (DASC)*, pp. 1–10. IEEE, 2024.
- [5] Stein Stroobants, Christophe De Wagter, and Guido CHE De Croon. Neuromorphic attitude estimation and control. *IEEE Robotics and Automation Letters*, 2025.
- [6] Federico Paredes-Vallés, Jesse J Hagenaars, Julien Dupeyroux, Stein Stroobants, Yingfu Xu, and Guido CHE de Croon. Fully neuromorphic vision and control for autonomous drone flight. *Science Robotics*, Vol. 9, No. 90, p. eadi0591, 2024.
- [7] Yin-Ching Lee, Sebastiano Mengozzi, Luca Zanatta, Andrea Bartolini, Andrea Acquaviva, and Francesco Barchi. Bio-inspired drone control: A reinforcement learning-trained spiking neural networks for agile navigation in dynamic environment. In *2025 IEEE International Conference on Omni-layer Intelligent Systems (COINS)*, pp. 1–8. IEEE, 2025.